Taller 1.1 – Modelos de Regresión Lineal y Polinomial Housing California: Predicción de Valores de Vivienda

Análisis de Regresión en Machine Learning

March 4, 2026

1 Resumen Ejecutivo

Este informe presenta el desarrollo completo de un sistema predictivo utilizando dos modelos de regresión:

1. **Regresión Lineal Múltiple**: modelo baseline simple.
2. **Regresión Polinomial**: modelos de grado 2 y 3 para capturar relaciones no-lineales.

Se utilizó el dataset *California Housing* para predecir el valor medio de viviendas en distritos de California. El proyecto sigue la metodología CRISP-DM (Comprensión → Modelado → Evaluación → Despliegue) y entrega tanto un backend API (FastAPI) desplegado en Render como una interfaz web interactiva (HTML + Streamlit).

Resultado principal: El modelo de Regresión Polinomial de grado 2 obtiene el mejor desempeño, con $R^2 = 0.6070$ y RMSE = 0.7176 (unidades de 100k USD).

2 Conceptos Teóricos Fundamentales

2.1 Regresión Lineal Múltiple

La regresión lineal múltiple modela la relación entre una variable objetivo y y múltiples variables predictoras $\mathbf{X}$ mediante:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \epsilon$$

donde:

- y es la variable objetivo (MedHouseVal en nuestro caso).
- $x_1, \ldots, x_p$ son las variables predictoras (MedInc, HouseAge, AveRooms, etc.).
- $\beta_0, \beta_1, \ldots, \beta_p$ son los coeficientes a estimar.
- ϵ es el término de error.

El objetivo es minimizar la suma de cuadrados de los errores (suma de cuadrados de residuos):

$$\text{SSE} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

2.2 Regresión Polinomial

La regresión polinomial extiende el modelo lineal al incluir términos polinómicos y de interacción. Para polinomios de grado d, el modelo se transforma según:

$$\mathbf{X}_{\text{poly}} = \left[1, x_1, x_2, \ldots, x_1x_2, x_1^2, x_2^2, \ldots, x_p^d\right]$$

Luego se aplica regresión lineal sobre el espacio expandido $\mathbf{X}_{\text{poly}}$. Esto permite capturar relaciones no-lineales entre características y el target, a costa de mayor riesgo de overfitting con grados muy altos.

2.3 Métricas de Evaluación

2.3.1 Coeficiente de Determinación (R^2)

Mide qué porcentaje de la varianza de y es explicado por el modelo:

$$R^2 = 1 - \frac{\text{SSE}}{\text{SST}} = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

Rango: $[0, 1]$. Un R^2 cercano a 1 indica buen ajuste.

2.3.2 Error Cuadrático Medio (RMSE)

Es la raíz cuadrada del error cuadrático medio, en las mismas unidades que y:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Permite interpretar el error típico en términos prácticos.

2.3.3 Análisis de Residuos

Los residuos $\hat{\epsilon}_i = y_i - \hat{y}_i$ deben distribuirse aleatoriamente alrededor de 0 sin patrones sistemáticos. Si hay patrones, indica violación de supuestos (linealidad, homocedasticidad).

3 Descripción del Dataset

3.1 California Housing

El dataset contiene información de 20,640 distritos de California, con 8 características originales:

- **MedInc**: Ingreso mediano del distrito (en decenas de miles de USD).
- **HouseAge**: Edad media de las viviendas (en años), capped a 52.
- **AveRooms**: Número promedio de habitaciones por vivienda.
- **AveBedrms**: Número promedio de dormitorios por vivienda.
- **Population**: Población del distrito.
- **AveOccup**: Ocupación promedio (personas por vivienda).
- **Latitude**: Latitud del distrito.
- **Longitude**: Longitud del distrito.
- **MedHouseVal** (TARGET): Valor medio de la vivienda en el distrito (en cientos de miles de USD).

Nota: En este proyecto utilizamos 7 features (excluimos AveOccup) para mantener simplicidad.

4 Análisis Exploratorio de Datos (EDA)

4.1 Estadísticos Descriptivos

La tabla de correlaciones (heatmap) revela que las variables más correlacionadas con MedHouseVal son:

1. **MedInc** ($r \approx 0.69$): Fuerte correlación positiva; distritos con mayor ingreso tienen viviendas más caras.
2. **Latitude** ($r \approx 0.14$): Correlación moderada; proximidad a la costa influye en precios.
3. **Longitude** ($r \approx -0.05$): Correlación débil con el target.

4.2 Visualización: Scatter Plots

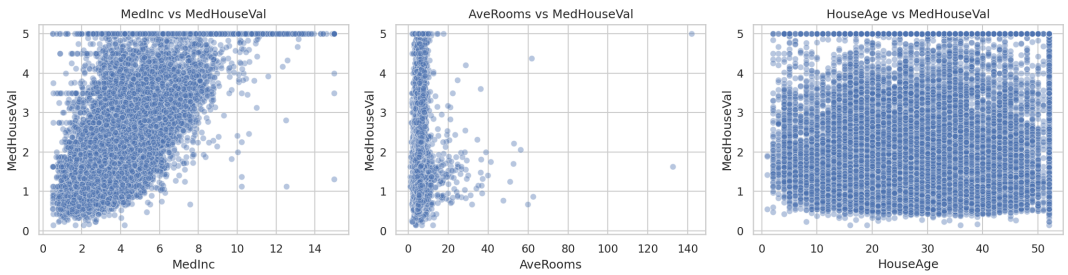

Figure 1: Relación entre las variables más importantes y el valor medio de vivienda. Se observa una relación no-lineal entre MedInc y MedHouseVal, especialmente en los extremos.

4.3 Matriz de Correlación

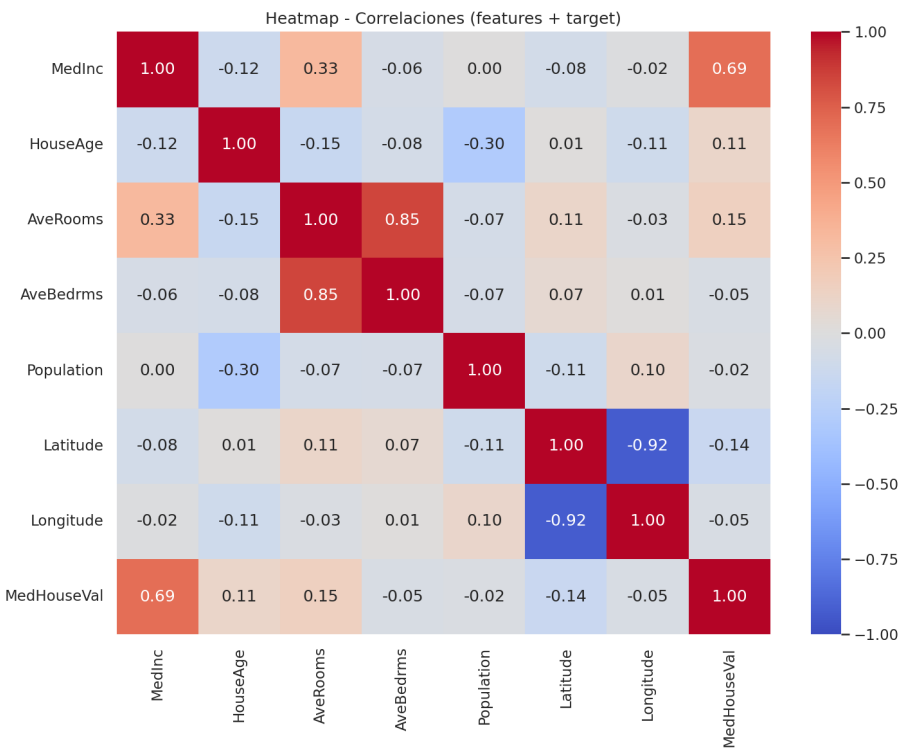

Figure 2: Heatmap de correlaciones. Nótese que MedInc tiene la correlación más fuerte con el target.

5 Metodología: CRISP-DM

Nuestro proyecto sigue las fases de CRISP-DM:

5.1 I. Comprensión de Datos

- Carga del dataset: 20,640 registros, 8 features + 1 target.
- Análisis de correlaciones y distribuciones.
- Identificación de variables clave.

5.2 II. Preparación y Modelado

- Split train/test: 80/20 con seed=42 para reproducibilidad.
- Entrenamiento de tres modelos:
  1. Regresión Lineal Múltiple (baseline).
  2. Regresión Polinomial de grado 2.
  3. Regresión Polinomial de grado 3.

5.3 III. Evaluación

- Cálculo de R^2 y RMSE en el conjunto de prueba.
- Análisis de residuos para detectar patrones.
- Comparativa de modelos.

5.4 IV. Despliegue

- API REST (FastAPI) en Render.
- Interfaz HTML interactiva.
- Aplicación Streamlit en Hugging Face Spaces (opcional).

6 Resultados del Modelado

6.1 Comparativa de Métricas

En el conjunto de prueba (test set):

Modelo	R^2	RMSE
Regresión Lineal Múltiple	0.5751	0.7462
Regresión Polinomial (grado 2)	0.6070	0.7176
Regresión Polinomial (grado 3)	0.5393	0.7770

Table 1: Desempeño de los tres modelos evaluados. El modelo polinomial de grado 2 presenta el mejor balance.

6.2 Interpretación

- **Modelo de referencia (Lineal):** Explica el 57.51% de la varianza. Error típico de ± 0.7462 en unidades de 100k USD ($\approx$ USD 74,620).
- **Polinomio grado 2 (MEJOR):** Explica el 60.70% de la varianza, mejorando un 3.2% respecto a lineal. RMSE desciende a 0.7176 ($\approx$ USD 71,760). Las interacciones y términos cuadráticos capturan mejor la no-linealidad observada en scatter plots.
- **Polinomio grado 3:** Explica menos (53.93%) y tiene RMSE más alto (0.7770). Indicativo de **overfitting**: el modelo se ajusta demasiado al ruido en entrenamiento y generaliza peor en nuevos datos. Con 35 features (7 originales + interacciones + cúbicos), la maldición de la dimensionalidad juega en contra.

6.3 Análisis de Residuos

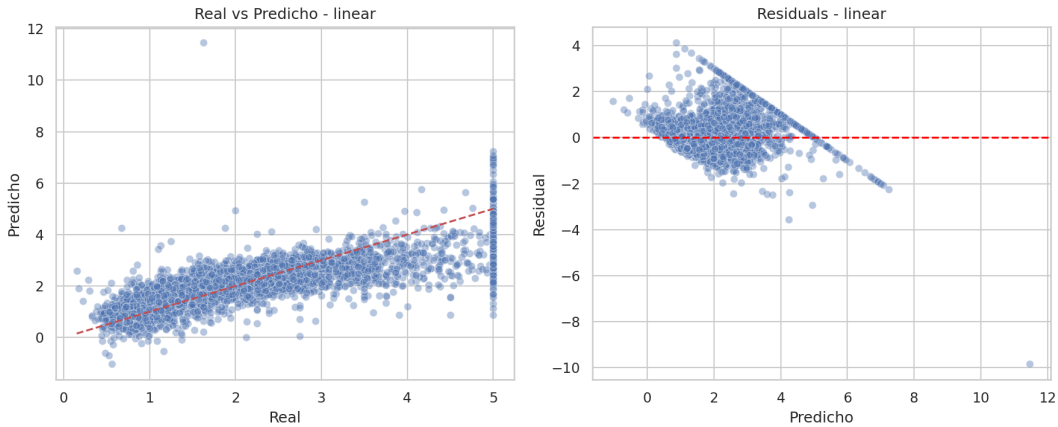

Figure 3: Regresión Lineal: Real vs Predicho (izq) y Residuos vs Predicho (der). Se observa heteroscedasticidad: la varianza de residuos aumenta para predicciones mayores.

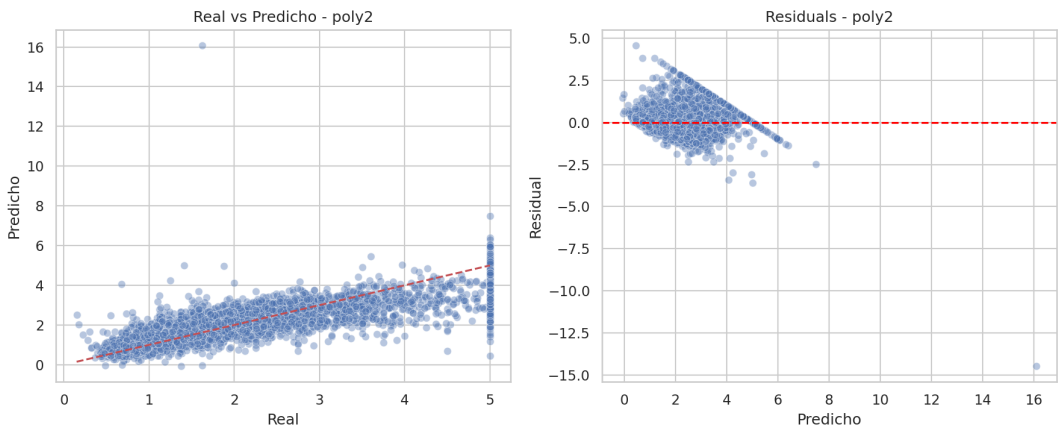

Figure 4: Polinomial grado 2: Mejor alineación con la diagonal (real = predicho) y residuos más compactos.

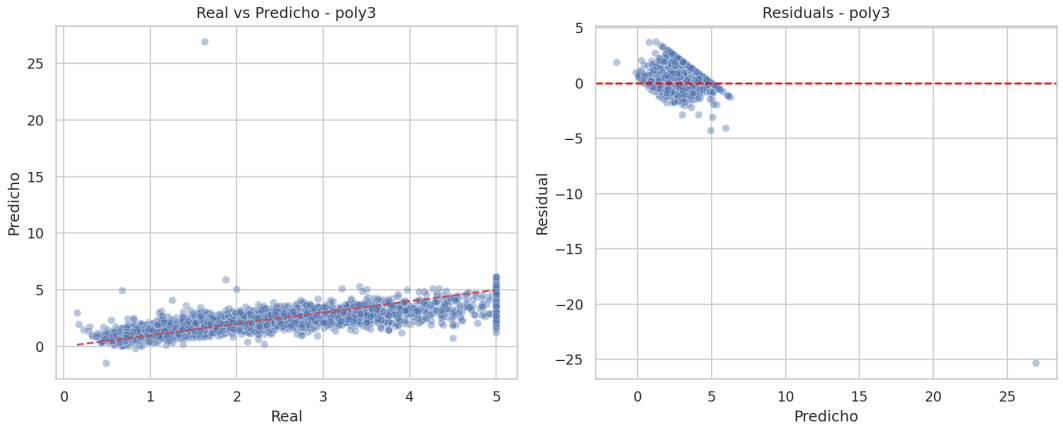

Figure 5: Polinomial grado 3: Residuos dispersos, típico de overfitting. El modelo no generaliza bien.

7 Justificación del Modelo Seleccionado

Se selecciona **Regresión Polinomial de grado 2** por:

1. **Mejor rendimiento**: $R^2 = 0.6070$ y RMSE $= 0.7176$, superiores a lineal.
2. **Evita overfitting**: A diferencia de grado 3, mantiene un equilibrio entre complejidad y generalización.
3. **Interpretabilidad**: 28 features (vs. 35 en grado 3) aún es manejable.
4. **Justificación teórica**: El EDA mostró relaciones no-lineales; los términos cuadráticos e interacciones son suficientes para capturar esas dinámicas.

8 Despliegue e Implementación

8.1 Arquitectura del Sistema

El proyecto se estructura en tres componentes:

8.1.1 1. Backend API (FastAPI)

- Framework: FastAPI + Uvicorn.
- Endpoint: POST /predict recibe JSON con las 7 features.
- Respuesta: predicción del modelo polinomial.
- Hosting: Render (https://housing-california-api.onrender.com).
- Despliegue: Docker, build automático desde Dockerfile.api en GitHub.

8.1.2 2. Frontend HTML

- Formulario interactivo centrado, con campos para todas las features.
- Botón Predecir: envía datos a la API y muestra resultado.
- Botón Simular: genera valores aleatorios para explorar casos distintos.
- Resultado: muestra predicción en formato decimal y equivalente en USD (ej: 0.49 = USD 49,000).
- Archivo: web/index.html (disponible en GitHub).

8.1.3 3. Frontend Streamlit (Opcional)

- App interactiva: sliders para cada feature.
- Llamadas a la API remota en Render.
- Despliegue: Hugging Face Spaces.

8.2 Flujo de Predicción

Cuando un usuario envía datos:

1. Input: {MedInc: 3.0, HouseAge: 30, ...}
2. Request HTTP POST a la API remota.
3. API carga transformador PolynomialFeatures (grado 2).
4. Transforma input de 7 a 28 features.
5. Predice con modelo pre-entrenado.
6. Devuelve resultado JSON con predicción.

8.3 Persistencia de Modelos

Los modelos se entrenan una sola vez localmente y se serializan:

- models/model_linear.joblib
- models/model_poly_2.joblib
- models/poly_2_transform.joblib (PolynomialFeatures)
- models/model_poly_3.joblib
- models/poly_3_transform.joblib

Estos archivos se incluyen en el repositorio GitHub y se copian al contenedor Docker durante el build.

9 Instrucciones de Uso

9.1 Instalación Local

Para ejecutar el proyecto localmente:

1. Clonar repositorio: git clone https://github.com/Honorio-Morales/housingCalifornia.git
2. Navegar a directorio: cd housingCalifornia
3. Crear entorno virtual: python -m venv .venv
4. Activar entorno: source .venv/bin/activate
5. Instalar dependencias: pip install -r requirements.txt
6. Entrenar modelos (opcional): python src/train.py
7. Levantar API: uvicorn src.api:app –reload –host 0.0.0.0 –port 8000

8. Levantar Streamlit (otra terminal): streamlit run app/streamlit$_{app.py}$

9.2 Acceso a Recursos Desplegados

- Demo HTML: https://github.com/Honorio-Morales/housingCalifornia/blob/main/web/index.html
- API Docs (Swagger UI): https://housing-california-api.onrender.com/docs
- Health Check: curl https://housing-california-api.onrender.com/health
- Streamlit (HF Spaces): Disponible para desplegar manualmente desde el repositorio.

10 Conclusiones

1. Se desarrolló un sistema completo de predicción de precios de viviendas usando regresión lineal y polinomial.
2. El análisis EDA identificó MedInc como la variable clave, con relaciones no-lineales observables.
3. El modelo de Regresión Polinomial de grado 2 fue seleccionado como el mejor equilibrio entre rendimiento y generalización, con $R^2 = 0.6070$ y RMSE $= 0.7176$.
4. El proyecto implementa la metodología CRISP-DM completa, desde análisis hasta despliegue en producción.
5. La arquitectura es modular: la API es agnóstica respecto a la interfaz (HTML, Streamlit, etc.), permitiendo reutilización y escalabilidad.
6. El despliegue en Render proporciona disponibilidad 24/7 sin costo para demostración.
7. Se incluyó análisis de residuos y justificación clara de decisiones de modelado.
8. Los modelos están disponibles en producción y listas para ser utilizadas por usuarios finales.

11 Referencias

- Scikit-learn Documentation: https://scikit-learn.org
- California Housing Dataset: https://www.kaggle.com/datasets/camnugent/california-housing-prices
- FastAPI: https://fastapi.tiangolo.com
- Render: https://render.com
- Metodología CRISP-DM: IBM, 2000.
- Repositorio GitHub: https://github.com/Honorio-Morales/housingCalifornia